

知能システム学特論レポート

(DL2 班) Caffe on Ubuntu

2015 年 6 月 29 日

1 報告者

| | |
|----------|-------|
| 15344203 | 有田 裕太 |
| 15344206 | 緒形 裕太 |
| 15344209 | 株丹 亮 |
| 12104125 | 宮本 和 |

2 進行状況

- 理論研究
- 順伝播型ネットワークについて

3 理論研究

3.1 ユニットの出力

3.2 活性化関数

3.2.1 シグモイド関数

入力の絶対値が大きな値をとると、出力が飽和し一定値になり、その間の入力に対して出力が徐々にかつ滑らかに変化する関数。

3.2.2 正規化線形関数

シグモイド関数は入力の変動が大き過ぎると出力が 0 か 1 の値しかとれないが、正規化線形関数はバイアスがない場合、入力が 0 以上であれば出力が入力に比例する。

3.2.3 マックスアウト

K 個 1 つ 1 つが異なる重みとバイアスを持ち、それぞれの総入力を $u_{(j1)} \dots u_{(jk)}$ と別々に計算したあと、それぞれの最大値をユニットの出力とする。




Fig.1 典型的な活性化関数とその概形

$$u_{jk} = \sum w_{jik} z_i + b_{jk} \quad (1 \dots K) \quad (3.1)$$

$$f(u_j) = \max_{k=1 \dots K} (u_{jk}) \quad (3.2)$$

3.3 多層ネットワーク

Fig. 2 に 2 層構造のネットワークを示す. Fig. 2 (a) より各層を $l = 0, 1, 2$ とすると, $l = 1$ の層を入力層, $l = 2$ を中間層, 隠れ層, $l = 3$ を出力層と呼ぶ. 各層のユニットの入出力を区別するために, 入力を $\mathbf{u}^{(l)}$, 出力を $\mathbf{z}^{(l)}$ と定義すると, 中間層 ($l = 2$) のユニットの出力は以下の式で表される.

$$\mathbf{u}^{(2)} = \mathbf{W}^{(2)} \mathbf{x} + \mathbf{b}^{(2)} \quad (3.3)$$

$$\mathbf{z}^{(2)} = \mathbf{f}(\mathbf{u}^{(2)}) \quad (3.4)$$

$\mathbf{W}^{(2)}$ は入力層と中間層の結合重みであり, $\mathbf{b}^{(2)}$ は中間層のユニットに与えられたバイアスである. 同様にして $\mathbf{u}^{(3)}$, $\mathbf{z}^{(3)}$ は

$$\mathbf{u}^{(3)} = \mathbf{W}^{(3)} \mathbf{z}^{(2)} + \mathbf{b}^{(3)} \quad (3.5)$$

$$\mathbf{z}^{(3)} = \mathbf{f}(\mathbf{u}^{(3)}) \quad (3.6)$$

となり, 任意の階層 L のネットワークに一般化すると

$$\mathbf{u}^{(l+1)} = \mathbf{W}^{(l+1)} \mathbf{z}^{(l)} + \mathbf{b}^{(l+1)} \quad (3.7)$$

$$\mathbf{z}^{(l+1)} = \mathbf{f}(\mathbf{u}^{(l+1)}) \quad (3.8)$$

と書ける. $l = 1, 2, 3, \dots, L-1$ の順に繰り返していくと最終的な出力 \mathbf{y} を決定することができる. この出力を決定するのは各層間の結合重み $\mathbf{W}^{(l)}$ ($l = 2, \dots, L$) とユニットのバイアス $\mathbf{b}^{(l)}$ ($l = 2, \dots, L$) である. これらのパラメータを持つベクトル \mathbf{w} を定義して, $\mathbf{y}(\mathbf{x}; \mathbf{w})$ と表現する.

3.4 出力層の設計と誤差関数

3.4.1 学習の枠組み

順伝播型ネットワークが表現する関数 $\mathbf{y}(\mathbf{x}; \mathbf{w})$ をネットワークのパラメータ \mathbf{w} を変えることで変化させ, 望みの関数を与えることを考える. 入力 \mathbf{x} と望みの出力 \mathbf{d} のペアを次のように与える.

$$\{(\mathbf{x}_1, \mathbf{d}_1), (\mathbf{x}_2, \mathbf{d}_2), \dots, (\mathbf{x}_N, \mathbf{d}_N)\} \quad (3.9)$$




Fig.2 2層のネットワーク

これらのペア (\mathbf{x}, d) 1つ1つを訓練サンプル (training samples) といい、その集合を訓練データ (training data) という。ネットワーク \mathbf{w} を調整することで訓練データの入出力ペアをできるだけ再現すること学習という。

この場合、ネットワークが表す関数と訓練データとの近さ $(\mathbf{y}(\mathbf{x}_n; \mathbf{w}))$ を誤差関数 (error function) で定義する。誤差関数は問題の種別や活性化関数によって異なる。Tab.1 に問題の種別ごとの活性化関数と誤差関数の一覧を示す。

Tab.1 問題の種別ごとの活性化関数と誤差関数

| 問題の種別 | 出力層の活性化関数 | 誤差関数 |
|--------|--------------|-------------------|
| 回帰 | 正接双曲線関数や恒等写像 | 二乗誤差 式 (3.10) |
| 二値分類 | ロジスティック関数 | 式 (3.11) |
| 多クラス分類 | ソフトマックス関数 | 交差エントロピー 式 (3.12) |

3.4.2 回帰

回帰 (regression) とは出力連続値をとる関数を対象に訓練データを良く再現する関数を求めることをいう。回帰では活性化関数に正接双曲線関数や恒等写像を用い、評価関数は次式が良く用いられる。

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \|\mathbf{d}_n - \mathbf{y}(\mathbf{x}_n; \mathbf{w})\|^2 \quad (3.10)$$

3.4.3 二値分類

二値分類では入力 \mathbf{x} に応じて2種類に区別する問題を考える。すなわち、 $d \in \{0, 1\}$ とする。このとき、活性化関数はロジスティック関数 $y = 1/(1 + \exp(-u))$ とし、誤差関数は次式で与える。

$$E(\mathbf{w}) = - \sum_{n=1}^N [d_n \log y(\mathbf{x}_n; \mathbf{w}) + (1 - d_n) \log \{1 - y(\mathbf{x}_n; \mathbf{w})\}] \quad (3.11)$$

3.4.4 多クラス分類

多クラス分類とは入力 \mathbf{x} に応じて有限個のクラスに分類する問題である。一例として Fig に手書き文字認識の例を示す。この問題では活性化関数にはソフトマックス関数 (softmax function) が良く用いられる。ま

た，誤差関数は次式で与える．

$$E(\boldsymbol{w}) = - \sum_{n=1}^N \sum_{k=1}^N d_{nk} \log y_k(\boldsymbol{x}_n; \boldsymbol{w}) \quad (3.12)$$

なお，この関数は交差エントロピー (cross entropy) と呼ばれる．

4 今後の課題

- 理論研究を進める．
- Caffe を使いこなす